



# **Diplomado en Ciencia de Datos UNAM**

## **Módulo 13 Datos Masivos**

### **Sesión 3 del 23 Septiembre de 2023**

---

**Sergio Ibarra Ramírez**

# Pantalla de Job de pysparkSQL ejecutado

The screenshot displays the Google Cloud Dataproc console interface. At the top, a banner indicates the status of the free trial: "Estado de la prueba gratuita: Te quedan \$4,924.58 de crédito y 76 días. Con una cuenta completa, obtendrás acceso ilimitado a todas las funciones de Google Cloud Platform." Below this, the navigation bar shows "Google Cloud", "My First Project", and a search bar. The left sidebar contains the "Dataproc" menu with options like "Trabajos alojados en clúster...", "Clústeres", "Trabajos" (selected), "Flujos de trabajo", "Políticas de ajuste de esc...", "Sin servidores", "Lotes", "Interactiva", "Servicios de Metastore", and "Notas de versión". The main content area is titled "Detalles del trabajo" and includes buttons for "CLONAR", "BORRAR", "DETENER", and "ACTUALIZAR". A table displays job details: ID de trabajo (job-f6329fb6), UUID de trabajo (f07a7e00-e7c1-422f-8c63-40be4012a9e4), Tipo (Trabajo de Dataproc), and Estado (Completado). Below the table, there are tabs for "SUPERVISIÓN" and "CONFIGURACIÓN". The "Resultado" section shows "UNIÓN DE LÍNEA: DESACTIVADA" and a message: "Los trabajos de Spark tardan alrededor de 60 segundos en iniciar recursos." A log entry shows: "23/09/23 15:24:42 INFO metastore: Trying to connect to metastore with URI thrift://cluster-sir-dcd05-m:9083", "23/09/23 15:24:42 INFO metastore: Opened a connection to metastore, current connections: 2", and "23/09/23 15:24:42 INFO metastore: Connected to metastore." A modal dialog box at the bottom center states: "El trabajo job-f6329fb6 se envió correctamente." The browser's address bar shows the URL "https://console.cloud.google.com/dataproc/j...".

Google Cloud

My First Project

Buscar (/) recursos, documentos...

Buscar

Dataproc

Trabajos alojados en clúster...

Clústeres

Trabajos

Flujos de trabajo

Políticas de ajuste de esc...

Sin servidores

Lotes

Interactiva

Servicios de Metastore

Notas de versión

Detalles del trabajo

CLONAR

BORRAR

DETENER

ACTUALIZAR

ID de trabajo	job-f6329fb6
UUID de trabajo	f07a7e00-e7c1-422f-8c63-40be4012a9e4
Tipo	Trabajo de Dataproc
Estado	Completado

SUPERVISIÓN

CONFIGURACIÓN

Resultado

UNIÓN DE LÍNEA: DESACTIVADA

Los trabajos de Spark tardan alrededor de 60 segundos en iniciar recursos.

IGNORAR

23/09/23 15:24:42 INFO metastore: Trying to connect to metastore with URI thrift://cluster-sir-dcd05-m:9083

23/09/23 15:24:42 INFO metastore: Opened a connection to metastore, current connections: 2

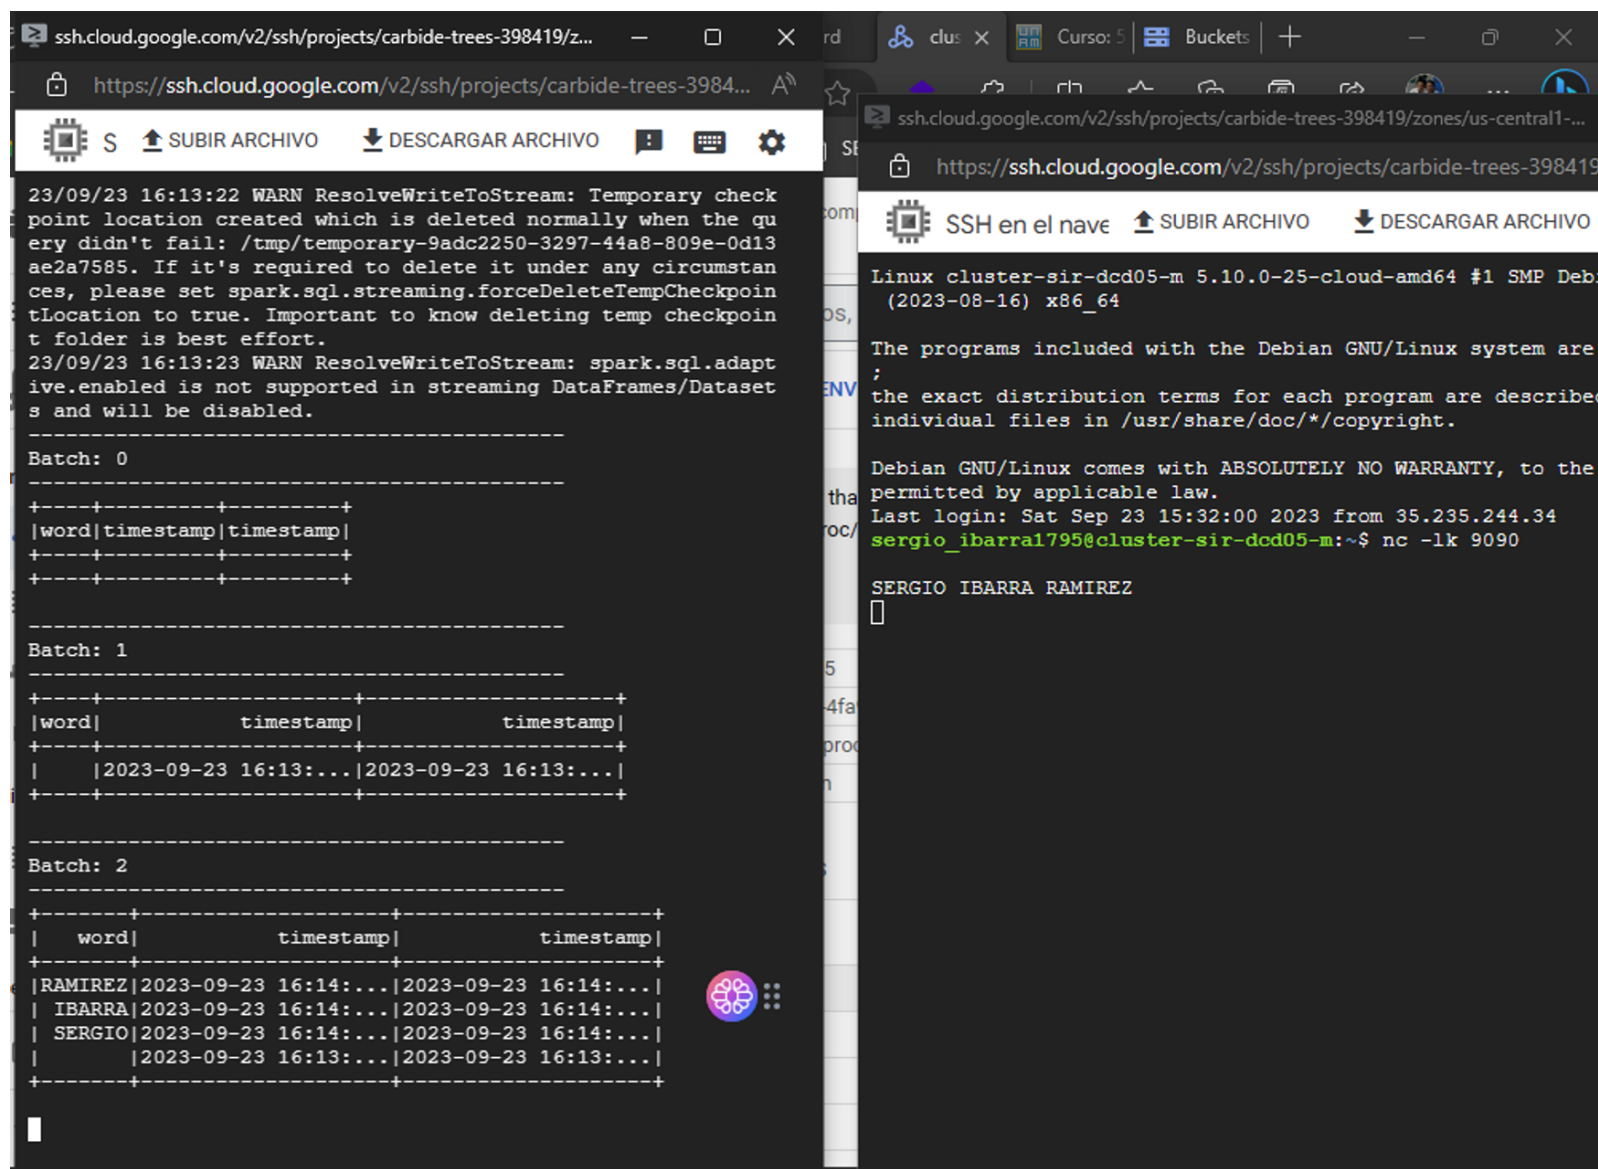
23/09/23 15:24:42 INFO metastore: Connected to metastore.

El trabajo job-f6329fb6 se envió correctamente.

# Pantalla 2

```
ivysettings.xml file not found in HIVE_HOME or HIVE_CONF_DIR
/etc/hive/conf.dist/ivysettings.xml will be used
23/09/23 15:36:02 INFO SparkEnv: Registering MapOutputTracker
23/09/23 15:36:02 INFO SparkEnv: Registering BlockManagerMaster
23/09/23 15:36:02 INFO SparkEnv: Registering BlockManagerMasterHeartbeat
23/09/23 15:36:02 INFO SparkEnv: Registering OutputCommitCoordinator
Spark master: yarn, Application Id: application_1695479716378_0002
2020      6      64
2020     11     18
2020      3     36
2020      9     24
2020     12     32
2020      4     44
2021      3      2
2021      2     10
2020      1    19428
2020      8     42
2021      1     34
2020      7     52
2020      2    132
2020     10     40
2020      5     42
Time taken: 12.108 seconds, Fetched 15 row(s)
sergio_ibarra1795@cluster-sir-dcd05-m:~$ hdfs dfs -ls hdfs://tmp/dcd/job/covid
Found 3 items
-rw-r--r--  2 sergio_ibarra1795 hadoop          0 2023-09-23 15:33 hdfs:///tmp/dcd/job/covid/_SUCCESS
-rw-r--r--  2 sergio_ibarra1795 hadoop    23886 2023-09-23 15:33 hdfs:///tmp/dcd/job/covid/part-00000-3233f9b8-c000-fb4-b5fd-89dbf1ecbdea-c000.snappy.parquet
-rw-r--r--  2 root hadoop    23886 2023-09-23 15:24 hdfs:///tmp/dcd/job/covid/part-00000-a629d3cf-ea1f-4ff6-9f9a-c0bf253c6740-c000.snappy.parquet
sergio_ibarra1795@cluster-sir-dcd05-m:~$
```

# Pantalla 3



# Pantalla 4

carbide-trees-398419 > cluster-sir-dcd05 [Sign out](#)

jupyter Mod13\_Sesion3\_parte2\_vista\_de\_SQL\_dentro\_de\_pyspark (autosaved)

File Edit View Insert Cell Kernel Widgets Help Trusted | PySpark

In [23]:

```
sql = """
SELECT ENTIDAD_UM, SEXO, SUM(EDAD) EDAD_SUMA, AVG(EDAD) EDAD_PROMEDIO, MAX(EDAD) EDAD_MAXIMA, MIN(EDAD)
FROM covid_df
GROUP BY ENTIDAD_UM, SEXO
HAVING SUM(EDAD) > 0
ORDER BY 4 DESC
"""

spark.sql(sql).show()
```

ENTIDAD_UM	SEXO	EDAD_SUMA	EDAD_PROMEDIO	EDAD_MAXIMA	EDAD_MINIMA
18	1	1426	47.53333333333333	83	15
18	2	1220	46.92307692307692	84	8
20	2	3790	44.06976744186046	82	13
14	2	10829	44.020325203252035	97	1
07	2	1359	43.83870967741935	87	0
20	1	4511	43.375	94	0
25	2	4778	43.04504504504504	89	0
26	2	5235	42.90983606557377	90	9
30	2	5192	42.90909090909091	98	0
15	1	13333	42.73397435897436	89	0
13	2	3990	42.4468085106383	83	7
28	2	6613	42.39102564102564	98	0
06	2	2020	42.083333333333336	78	10
17	2	1555	42.027027027027025	84	0
30	1	6534	41.88461538461539	97	5
28	1	8333	41.665	85	9
08	2	19910	41.65271966527197	92	0
09	2	112557	41.54928017718716	97	0